


Intro to ML

Clustering



Plan zajęć



1

Co to clustering?

2

Zastosowania

3

Typy algorytmów

4

K-means

5


Hierarchical clustering

6


DBSCAN

Co to clustering?

Techniki klasteryzacji w uczeniu maszynowym polegają na podziale **danych nieoznaczonych** lub punktów danych na różne klastry w taki sposób, aby podobne punkty danych znajdowały się w tym samym klastrze, a te różniące się od innych były w innych klastrach. Mówiąc prościej, celem procesu klasteryzacji jest **segregowanie grup o podobnych cechach** i przypisywanie ich do odpowiednich klastrów.





Original Data



Clustering


Clustered Data





Różnica między clustering(klasteryzacją) a classification(klasyfikacją)

- Klasyfikacja: Dane oznaczone (supervised learning).
- Klasteryzacja: Dane nieoznaczone (unsupervised learning).



Classification	Clustering
Model predicts a probable classification for a given input	Model maps a given input into one of the data clusters
Uses supervised learning	Uses unsupervised learning
Labeled data required for training	Does not require labeled data
Number of categories is known	Number of groups is unknown
Two-step process to train and predict	Single-step process

Zastosowania Klasteryzacji

- 1. Segmentacja klientów (marketing)

Klasteryzacja w marketingu pomaga w segmentacji klientów, umożliwiając firmom lepsze zrozumienie różnych grup konsumentów i dostosowanie strategii do ich potrzeb.

- Przykłady zastosowań:

- Segmentacja demograficzna: Grupy klientów według wieku, płci, lokalizacji.
- Segmentacja behawioralna: Podział na podstawie zachowań zakupowych (np. klienci regularni, klienci okazjonalni).
- Segmentacja na podstawie wartości: Klienci o wysokim LTV (Lifetime Value) vs. klienci jednorazowi.
- Personalizacja ofert: Dzięki klasteryzacji firmy mogą kierować spersonalizowane reklamy lub oferty promocyjne do odpowiednich grup.
- Przykład techniczny: Algorytm k-means może podzielić klientów na grupy na podstawie takich cech jak częstotliwość zakupów i średnia wartość koszyka.

Zastosowania Klasteryzacji

- 2. Analiza obrazów (rozpoznawanie wzorców)

Klasteryzacja jest używana do analizy i przetwarzania obrazów, szczególnie w kontekście rozpoznawania wzorców i segmentacji obrazów.

- Przykłady zastosowań:
 - Segmentacja obrazu: Wykrywanie obiektów w obrazie poprzez grupowanie pikseli o podobnej intensywności lub kolorze.
 - Rozpoznawanie obiektów: Identyfikowanie obiektów na podstawie ich cech wizualnych, takich jak kształt czy tekstura.
 - Redukcja wymiarowości: Klasteryzacja w połączeniu z PCA (Principal Component Analysis) pomaga w redukcji danych w dużych obrazach.
 - Przykład techniczny: Algorytm DBSCAN może identyfikować obiekty w obrazach o nieregularnych kształtach.

Zastosowania Klasteryzacji

- 3. Biomedycyna (grupowanie genów)

W biomedycynie klasteryzacja odgrywa kluczową rolę w analizie dużych zestawów danych biologicznych.

- Przykłady zastosowań:

- Analiza ekspresji genów: Grupowanie genów o podobnych wzorcach ekspresji, co może pomóc w identyfikacji genów odpowiedzialnych za określone choroby.
- Identyfikacja podtypów chorób: Klasteryzacja danych medycznych (np. genomowych, proteomicznych) pomaga w klasyfikacji pacjentów do grup chorobowych.
- Projektowanie leków: Grupowanie związków chemicznych na podstawie ich właściwości biologicznych.
- Przykład techniczny: Klasteryzacja hierarchiczna może być używana do analizy relacji między genami i budowy dendrogramów.

Zastosowania Klasteryzacji

- 4. Analiza tekstu (grupowanie dokumentów)

Klasteryzacja jest szeroko stosowana w przetwarzaniu języka naturalnego (NLP) do organizacji i analizy dokumentów tekstowych.

- Przykłady zastosowań:
 - Grupowanie podobnych dokumentów: Tworzenie klastrów z artykułów prasowych, e-maili lub postów na forach na podstawie ich zawartości.
 - Analiza tematów: Automatyczne identyfikowanie tematów w dużych zbiorach danych tekstowych.
 - Filtrowanie spamu: Grupowanie wiadomości e-mail na podstawie ich cech tekstowych.
 - Wyszukiwarki internetowe: Klasteryzacja wyników wyszukiwania na tematyczne grupy, aby poprawić trafność wyników.
 - Przykład techniczny: Algorytm k-means może grupować dokumenty na podstawie reprezentacji wektorowej (np. TF-IDF lub embeddingów).




Różne typy algorytmów klasteryzacji

Modele oparte na centroidach

Algorytmy te iteracyjnie określają podobieństwo na podstawie bliskości punktu danych do centroidu lub środka klastra. Przykładem tego typu algorytmu jest popularny **k-means**. Modele te wymagają wcześniejszego określenia liczby klastrów, co wymaga posiadania pewnej wiedzy o zbiorze danych. Algorytmy działają iteracyjnie, aby odkrywać lokalne optima.

Centroid - punkt reprezentujący środek klastra, obliczany jako średnia arytmetyczna współrzędnych wszystkich punktów należących do danego klastra. Jest to referencyjny punkt, wokół którego grupowane są dane w trakcie iteracyjnego procesu klasteryzacji


K-means




K-means

1. Zaczynamy od wyboru liczby K ; jest to liczba centroidów - liczba klastów (clusters) którą otrzymamy;
2. Inicjalizacja: Wybieramy K punktów ze zbioru danych (dataset); to one będą nam służyły jako początkowe centroidy do klasteryzacji.
3. Przyporządkowywanie: Dla każdego punktu z naszego zbioru danych obliczamy dystans między nim a każdym z K centroid i przyporządkowujemy go do tego centroidu, który jest do niego najbliższy; po tym kroku mamy K klastrów (clusters)
4. Aktualizujemy centroidy: Po przypisaniu każdego z n punktów do k centroidów, ponownie przeliczamy centroidy klastrów - bierzemy średnią ze wszystkich punktów w tym klastrze.
5. Powtarzamy punkty 3 i 4 dopóki znajdzie zbieżność tzn. do wtedy gdy centroidy nie będą się zmieniały (lub znacząco zmieniały).
6. Wynik końcowy

Jak wybrać K?




K-means




Step 1: Wybieramy k- tutaj
niech $k=2$

K-means




Step 2: Wybieramy k punktów
jako wstępne centroidy

K-means




Step 3: Przydzielamy punkty do
najbliższej centroidy

K-means




Step 4: Przeliczamy centroidy
dla każdego z klastrów




Nowy centroid

K-means




Step 5: Powtarzamy krok 3 oraz

4



Nowy centroid


K-means



Step 5: Powtarzamy krok 3 -
przydzielmy wszystkie n
punktów do najbliższej centroidy

Nowy centroid


K-means



Step 5: Powtarzamy krok 4 -
przeliczamy ponownie centroidy


Nowy centroid

K-means




Step 1: Wybieramy K;
Niech to będzie $k=5$

K-means




Step 2: Wybieramy k punktów
jako wstępne centroidy

K-means



Step 3: Przydzielamy punkty do
najbliższej centroidy


K-means



Step 4: Przeliczamy centroidy
dla każdego z klastrów


K-means

Step 5a: Powtarzamy krok 3 -
przydzielmy wszystkie n
punktów do najbliższej centroidy




K-means

Step 5b: Powtarzamy krok 4 -
przeliczamy ponownie centroidy




K-means

Step 5a: Powtarzamy krok 3 -
przydzielmy wszystkie n
punktów do najbliższej centroidy




K-means

Step 5b: Powtarzamy krok 4 -
przeliczamy ponownie centroidy




K-means

Step 5a: Powtarzamy krok 3 -
przydzielmy wszystkie n
punktów do najbliższej centroidy




K-means

Step 5b: Powtarzamy krok 4 -
przeliczamy ponownie centroidy



K-means



Step 6: Koniec

Modele oparte na łączności


Modele te opierają się na założeniu, że punkty danych bliżej siebie w przestrzeni danych są bardziej podobne niż punkty leżące dalej od siebie. Modele te mogą działać w dwóch podejściach:

- 1) **AGGLOMERATIVE** Wszystkie punkty danych są początkowo traktowane jako oddzielne klastry, które następnie są łączone w miarę zmniejszania się odległości między nimi.
- 2) **DIVISIVE** Wszystkie punkty danych są początkowo traktowane jako jeden klaster, który następnie jest dzielony w miarę zwiększania się odległości.

Wybór funkcji odległości w tych modelach jest subiektywny. Modele te są łatwe do interpretacji, ale mają ograniczoną skalowalność, co utrudnia pracę z dużymi zbiorami danych. Przykłady takich modeli to algorytmy **klasteryzacji hierarchicznej** i ich warianty.

Klasteryzacja hierarchiczna


1. Zaczynamy od traktowania każdego punktu ze zbioru danych jako osobny klaster; mając więc N danych, mamy wtedy N początkowych klastrów
2. Porównujemy dystanse pomiędzy klastrami; tutaj możemy rozważyć kilka miar dystansu np. euclidean distance;
3. Łączymy te klastry które są najbliższe sobie;
4. Aktualizujemy miary dystansów.
5. Powtarzamy krok 3 oraz 4 do momentu gdy otrzymamy 1 końcowy klaster.



Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

Step 1: Traktujemy każdy z punktów jako osobny klaster



Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

	A	B	C	D	E
A	0.00	5.39	5.00	1.00	2.24
B	5.39	0.00	2.83	5.10	5.66
C	5.00	2.83	0.00	4.24	6.32
D	1.00	5.10	4.24	0.00	3.16
E	2.24	5.66	6.32	3.16	0.00

Step 2: Porównujemy dystanse między klastrami, tutaj użyty jest Euclidean distance

Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

	A	B	C	D	E
A	0.00	5.39	5.00	1.00	2.24
B	5.39	0.00	2.83	5.10	5.66
C	5.00	2.83	0.00	4.24	6.32
D	1.00	5.10	4.24	0.00	3.16
E	2.24	5.66	6.32	3.16	0.00

Step 3: Łączymy najbliższe klastry

Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

Step 4: Aktualizujemy miary dystansów

Merging 1:


Merged clusters: ('A', 'D')

	B	C	E	(A+D)
B	0.00	2.83	5.66	5.10
C	2.83	0.00	6.32	4.24
E	5.66	6.32	0.00	2.24
(A+D)	5.10	4.24	2.24	0.00

Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

Step 4: Aktualizujemy miary dystansów



Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

Step 4: Aktualizujemy miary
dystansów

Merging 1:

Merged clusters: ('A', 'D')

	B	C	E	(A+D)
B	0.00	2.83	5.66	5.10
C	2.83	0.00	6.32	4.24
E	5.66	6.32	0.00	2.24
(A+D)	5.10	4.24	2.24	0.00

Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

Merging 1:
Merged clusters: ('A', 'D')

	B	C	E	(A+D)
B	0.00	2.83	5.66	5.10
C	2.83	0.00	6.32	4.24
E	5.66	6.32	0.00	2.24
(A+D)	5.10	4.24	2.24	0.00

Step 4: Aktualizujemy miary
dystansów

Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

Step 4: Aktualizujemy miary dystansów

Merging 2:


Merged clusters: ('E', '(A+D)')

	B	C	(E+(A+D))
B	0.00	2.83	5.10
C	2.83	0.00	4.24
(E+(A+D))	5.10	4.24	0.00

Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

Step 4: Aktualizujemy miary dystansów



Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

Step 4: Aktualizujemy miary dystansów

Merging 2:

Merged clusters: ('E', '(A+D)')

	B	C	(E+(A+D))
B	0.00	2.83	5.10
C	2.83	0.00	4.24
(E+(A+D))	5.10	4.24	0.00

Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

Step 4: Aktualizujemy miary
dystansów

Merging 2:

Merged clusters: ('E', '(A+D)')

	B	C	(E+(A+D))
B	0.00	2.83	5.10
C	2.83	0.00	4.24
(E+(A+D))	5.10	4.24	0.00

Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7


Step 4: Aktualizujemy miary
dystansów

```
Merging 3:  
Merged clusters: ('B', 'C')  
                  (E+(A+D)) (B+C)  
(E+(A+D))      0.00    4.24  
(B+C)          4.24    0.00
```

Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

Step 4: Aktualizujemy miary dystansów



Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

Step 4: Aktualizujemy miary
dystansów

```
Merging 3:  
Merged clusters: ('B', 'C')  
                  (E+(A+D)) (B+C)  
(E+(A+D))      0.00    4.24  
(B+C)          4.24    0.00
```

Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7

Step 4: Aktualizujemy miary
dystansów

Merging 3:

Merged clusters: ('B', 'C')

(E+(A+D)) (B+C)

(E+(A+D)) 0.00 4.24

(B+C) 4.24 0.00

Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7


```
Merging 4:  
Merged clusters: ('(E+(A+D))', '(B+C)')  
                  ((E+(A+D))+(B+C))  
                  ((E+(A+D))+(B+C)) 0.0
```

Step 4: Aktualizujemy miary
dystansów

Klasteryzacja hierarchiczna

Punkt	x	y
p1	1	5
p2	6	3
p3	5	5
p4	1	4
p5	2	7


Dendrogram



Modele oparte na gęstości


Modele te przeszukują przestrzeń danych w poszukiwaniu obszarów o zróżnicowanej gęstości punktów danych. Wykrywają różne gęste regiony i przypisują punkty znajdujące się w tych regionach do tego samego klastra. Popularne przykłady to **DBSCAN (Density-Based Spatial Clustering of Applications with Noise)** i OPTICS. Modele te są szczególnie przydatne do identyfikacji klastrów o dowolnym kształcie oraz wykrywania punktów odstających. Potrafią oddzielić punkty znajdujące się w rzadkich regionach od tych, które należą do gęstych obszarów danych.

DBSCAN




DBSCAN

DBSCAN



k-means




DBSCAN

Density-Based Spatial Clustering of Applications with Noise


1. Określamy parametry
 - a. eps (maksymalna odległość między punktami w klastrze).
 - b. minPts (minimalna liczba punktów w otoczeniu, aby punkt mógł być rdzeniem klastra).
2. Dla każdego punktu danych:
 - a. Obliczamy liczbę punktów znajdujących się w promieniu eps.
 - b. Jeśli liczba punktów $\geq \text{minPts}$, punkt staje się punktem rdzeniowym.
 - c. Jeśli nie, punkt nie jest punktem rdzeniowym i zostanie punktem brzegowym lub szumem.
3. Zaczynamy od dowolnego punktu rdzeniowego, oznaczamy go jako należącego do nowego klastra, następnie rozszerzamy klaster, dodając wszystkie punkty rdzeniowe w jego promieniu eps.
4. Do klastra stworzonego z punktów rdzeniowych dodajemy te punkty, które znajdują się w promieniu eps jakiegoś punktu rdzeniowego tego klastra.
5. Gdy przejdziemy przez wszystkie punkty brzegowe przechodzimy do kolejnego klastra

DBSCA

N




Step 1:
eps:



minPts: 2

DBSCA


N



Step 2: Identyfikujemy punkty
rdzeniowe

DBSCA


N



Step 2: Identyfikujemy punkty
rdzeniowe

DBSCA


N



Step 2: Identyfikujemy punkty
rdzeniowe

DBSCA


N



Step 2: Identyfikujemy punkty
rdzeniowe

DBSCA


N



Step 2: Identyfikujemy punkty
rdzeniowe

DBSCA

N




Step 2: Identyfikujemy punkty
rdzeniowe

DBSCA

N


Step 3: Zaczynamy od
dowolnego punktu rdzeniowego,
oznaczamy go jako **należącego
do nowego klastra**, następnie
rozszerzamy klaster, dodając
wszystkie **punkty rdzeniowe** w
jego promieniu eps



DBSCA

N


Step 3: Zaczynamy od
dowolnego punktu rdzeniowego,
oznaczamy go jako **należącego
do nowego klastra**, następnie
rozszerzamy klaster, dodając
wszystkie **punkty rdzeniowe** w
jego promieniu eps



DBSCA

N


Step 3: Zaczynamy od
dowolnego punktu rdzeniowego,
oznaczamy go jako **należącego
do nowego klastra**, następnie
rozszerzamy klaster, dodając
wszystkie **punkty rdzeniowe** w
jego promieniu eps



DBSCA



N

Step 3: Zaczynamy od
dowolnego punktu rdzeniowego,
oznaczamy go jako **należącego
do nowego klastra**, następnie
rozszerzamy klaster, dodając
wszystkie **punkty rdzeniowe** w
jego promieniu eps



DBSCA


N



Step 4: do stworzonego klastra
dodajemy border points- punkty
znajdujące się w odległości
maksymalnie eps od jakiegoś
punktu rdzeniowego

DBSCA


N



Step 4: do stworzonego klastra
dodajemy border points- punkty
znajdujące się w odległości
maksymalnie eps od jakiegoś
punktu rdzeniowego

DBSCA


N



Step 4: do stworzonego klastra
dodajemy border points- punkty
znajdujące się w odległości
maksymalnie eps od jakiegoś
punktu rdzeniowego

DBSCA


N



Step 5: Tworzymy kolejny
klaster, powtarzając
wcześniejsze kroki

DBSCA


N



Step 5: Tworzymy kolejny
klaster, powtarzając
wcześniejsze kroki

DBSCA

N



Te punkty które nie mają w promieniu eps żadnego punktu rdzeniowego są punktami odstającymi/ szumem

DBSCAN

<https://www.naftaliharris.com/blog/visualizing-dbscan-clustering/>